

Auditoría reutilizable de modelos de clasificación y regresión

Jorge Josué Flores González | Atlantis University

MAI 540 | Kevin A. Garcia Gallardo | 6 de octubre de 2026

La Skill convierte los errores de las tareas anteriores en criterios verificables. Se aplicó al archivo de biopsias recibido como original, a Iris y a un caso construido con Insurance. Detectó fuga de información y límites de evaluación; un resultado PASA no certifica seguridad clínica ni ausencia de sesgo.

Criterios y origen

Criterio	Origen y regla aplicada
Métricas	Biopsias reportaba solo accuracy. Se exige matriz, precisión, recall y F 1 de malignos; coherencia numérica con predicciones.
Partición y selección	Comparación de Iris: mismos folds y semilla. Ajustar transformaciones y elegir k dentro del entrenamiento externo.
Fuga	Biopsias incluye sesiones derivadas del diagnóstico. FALLA si un predictor depende del objetivo o información posterior.
Subgrupos	El desempeño global puede ocultar diferencias. Alerta >0.10 en recall o >20% relativo en RMSE; soporte mínimo 20 y 10 positivos para recall.

Los umbrales son exploratorios, fijados antes de revisar resultados. Cada veredicto cita celda o línea y usa PASA, FALLA o NO SE PUEDE DETERMINAR. La Skill no modifica las entradas. Para regresión se comprueba MSE, RMSE y R^2 ; un R^2 negativo es válido (scikit-learn developers, s. f.).

Repositorio: https://github.com/Jorgefloresraiz/Tarea_4_1


Resultados por proyecto

Proyecto	Detectado	Omisiones y falsos positivos
Biopsias recibido	Fuga; división por cero; falta de estratificación; solo accuracy; NameError en celda 11.	Detectó 2/2 defectos conocidos: fuga y división. Sin falso positivo confirmado en esos controles; no hay referencia exhaustiva.
Iris	KNN anidado correcto; selección exploratoria del árbol; faltan matrices OOF y subgrupos.	Temporalidad y costos requieren contexto. No se puede asegurar cero omisiones o falsos positivos.
Insurance	Métricas coherentes; interpretación residual incompleta; 3 predicciones negativas. Regiones bajo umbral.	Sin identidad de pacientes ni fechas de captura. No se infiere equidad causal ni ausencia total de fallos.

En biopsias corregido: precisión 0.6923, recall 0.5094 y F1 0.5870 para malignos. Detectó 27 de 53 malignos; priorizar recall responde al costo de los 26 falsos negativos. Es evidencia educativa, no validación clínica.

Figura 1

Comparación de los cinco clasificadores de Iris



Nota. Diez folds externos estratificados idénticos; KNN selecciona k en cinco folds internos.

Regresión logística: 96.67%; KNN: 96.00%; Random Forest: 95.33%. Barras: desviación estándar, no intervalos de confianza.

Refinamiento y estabilidad

La versión inicial omitía una regla explícita contra seleccionar hiperparámetros con todos los datos antes de validación externa. El caso deliberado `seleccion_global.py` expuso esa omisión en revisión manual; la versión 2 agregó P3. La versión 3 amplió la cobertura a regresión al incorporar Insurance. Los cambios están en commits separados.

Seis pruebas automáticas verificaron clase positiva 0, R^2 negativo, objetivo constante, soporte insuficiente, disparidad y valores no finitos. Dos procesos produjeron resultados numéricos idénticos. Dos lecturas manuales de Insurance conservaron los nueve veredictos y el hash; al ser de Codex en una misma conversación, no son pruebas ciegas ni garantía de estabilidad general. La prueba adicional en Wine identificó falta de errores por tipo de vino y de análisis residual en `main.py`. Fue una revisión estática; no se atribuyen resultados de ejecución. Insurance obtuvo RMSE 5940.03 frente a 13172.96 de referencia y R^2 0.7959. Ninguna región superó 20%, aunque southwest quedó a 19.38%.

Alcance y procedencia

Insurance fue elegido entre los datasets compartidos del aula y construido para este caso; no se atribuye al profesor un notebook inexistente. Biopsias se conservó tal como fue recibido por correo, sin verificar descarga directa del aula. La asistencia utilizada fue Codex, no Claude Code; esta diferencia y las limitaciones de las pruebas se declaran en la bitácora.

Referencias

Anthropic. (s. f.). Extend Claude with skills. <https://code.claude.com/docs/en/skills>

scikit-learn developers. (s. f.). Model evaluation: Quantifying the quality of predictions.

https://scikit-learn.org/stable/modules/model_evaluation.html